面向图像条件软传感器退化的可靠多模态垃圾分类方法

摘要

多模态垃圾分类可以借助视觉外观、类别语义和结构化属性估计，但附加模态在缺失、 噪声、偏移或卡死条件下也可能把低质量证据注入分类器。针对这一问题，本文提出一种 面向图像条件软传感器退化的可靠多模态分类方法。模型以 YOLO11 多尺度视觉表示和 CLIP 类别文本原型为语义上下文，编码与目标裁剪关联的4×4软传感器网格； 视觉–文本分支同时预测传感器潜表示和有界异方差，并由可用性、原始网格质量、 跨模态网格差异、潜表示一致性与不确定性共同估计样本级可靠性。观测缺失时，有效 传感器表示完全回退到预测潜表示；观测退化时，可靠性门控连续抑制观测残差。实验 使用 19 类、8654 个对象样本构成的内部固定基准，其中软传感器网格由图像统计或 视觉语言模型条件估计，并非同步物理传感器测量。在训练种子 42、43 和 44 上，完整方法的测试 Accuracy 为$88.26\% \pm 0.21$个百分点，Macro F1 为 $82.26\% \pm 0.31$个百分点。相对匹配训练的无可靠性变体，Accuracy 和 Macro F1 平均提高 0.81 和 0.51 个百分点，两个指标均在 3/3 个种子上方向一致。固定检查点干预 以及 missing、noise、bias、stuck 和 mixed 软件退化实验进一步表明，门控能够产生 符合设计预期的抑制与回退行为。潜空间方差与误差具有较好的相对排序，但绝对尺度 仍明显保守。上述结果支持该方法在已定义内部软件退化下的可靠融合能力；外部盲测、 同步硬件采集和物理量校准仍有待完成。

关键词：垃圾分类；多模态融合；软传感器；模态退化；可靠性门控； 不确定性

1 引言

垃圾识别已由封闭集对象分类逐步扩展到自然场景检测、工业传送带分割和自动分选。WasteNet 展示了边缘端视觉分类在智能垃圾桶中的可行路径[1]； TACO 以多边形标注刻画自然环境中的散落垃圾[2]，ZeroWaste 则 把研究推进到工业场景中密集、遮挡和可变形目标的实例分割[3]。近期 SortWaste 和 ScatSpotter 进一步提示，目标 尺度、拥挤度、伪装外观以及独立采集测试集都会改变识别结果的解释边界 [4], [5]。这些工作反映出垃圾类别外观 相似、背景复杂和样本分布长尾等困难，也说明对象分类、整图检测与实例分割应当 分别定义任务和指标。

除 RGB 外观外，材料响应和空间分布能够提供补充线索。已有垃圾分选研究融合 RGB、 近红外高光谱、热成像和太赫兹等同步观测[6]， SpectralWaste 还在真实分拣设施中建立了同步 RGB 与高光谱数据 [7]。这类独立物理模态具有明确的传感来源。与之不同， 本文当前使用的结构化属性由目标图像条件生成：视觉语言模型或确定性规则根据对象 裁剪估计一张4×4网格。该网格适合作为软传感器接口，用于验证融合、缺失 回退和软件退化机制，却不能替代同步硬件测量。若忽略这一来源差异，平均分类精度 很容易掩盖附加模态何时有效、何时失真以及模型是否真正抑制了错误证据。

一般多模态研究已经证明，融合结构不会天然抵抗模态缺失 [8]。现有工作分别从低质量输入的动态融合 [9]、缺失模态的分布一致恢复[10]、 单模态偶然不确定性[11]、概率式缺失模态映射[12]和超模态增强[13]等角度提升鲁棒性。然而， 面向图像条件软传感器的垃圾分类仍存在三个相互关联的问题：其一，观测网格与 RGB 共享信息来源，质量判断必须区分“有信息”与“独立物理证据”；其二，4×4 空间网格的异常既表现在潜表示差异，也表现在局部统计和跨模态形状不一致；其三， 仅报告最终 Accuracy 不足以证明可靠性门控确实响应了缺失或退化。

为此，本文构建视觉、类别文本与图像条件软传感器的统一对象级分类接口。视觉和 文本上下文预测可回退的传感器潜表示及其异方差，观测网格与预测 clean 网格的差异 连同可用性、原始网格统计和潜空间一致性共同形成可靠性门控。有效传感器表示写为 预测潜表示与观测残差的连续插值，因此同一结构能够覆盖正常利用、退化抑制和完全 缺失回退。实验不只比较最终指标，还采用同检查点路径干预、三个匹配训练种子的 独立重训消融、注册软件退化和源图聚类置信区间，分别检验门控行为、训练稳定性与 退化响应。

本文的主要贡献如下。

1. 提出一种面向图像条件4×4软传感器退化的可靠多模态垃圾分类结构， 将视觉–文本条件潜表示预测、观测回退和跨模态质量判别纳入同一前向过程。
2. 构建由可用性、原始网格质量、跨模态网格差异、潜表示一致性和异方差 不确定性共同驱动的样本级门控，并通过 clean 网格重建、可靠性校准和排序目标学习 退化程度。
3. 建立包含同检查点机制干预、三个匹配训练种子、五类单项及混合软件退化、 源图簇 bootstrap 和不确定性诊断的评价流程，同时保留类别平衡失败、历史消融 不显著和外部数据缺失等边界。

本文所有核心结果均限定于 19 类内部固定留出基准。当前 sidecar 不是同步硬件观测， 测试集也不是从未访问的外部盲测队列。

2 相关工作

2.1 垃圾分类与场景理解

早期垃圾识别通常把单个对象裁剪输入卷积网络，并以总体分类精度衡量系统性能。 这种设置便于嵌入式实现，但难以覆盖开放环境中的遮挡、密集目标和背景变化。 TACO、ZeroWaste、SortWaste 和 ScatSpotter 分别从野外垃圾、工业传送带、密集 分选和独立采集场景扩展了检测或分割任务 [2], [3], [4], [5]。 它们共同表明，数据单位、场景分布和评价协议决定了指标能够支持的结论。本文主 任务仍是已知目标框内的 19 类对象分类，因此采用 Accuracy、Macro F1 和校准指标；目标检测和分割只作为系统范围扩展，不能与对象级指标直接比较。

2.2 垃圾分选中的多模态信息

垃圾材料常具有相似颜色和形状，独立传感器可从光谱、热响应或太赫兹特征补充 视觉信息。Bihler 等融合多类物理传感数据进行大件垃圾分类 [6]，SpectralWaste 则为同步 RGB 和高光谱分割提供了 真实设施数据[7]。这些研究的优势来自物理来源的 互补性，同时要求时间同步、空间配准和设备标定。本文侧重另一层问题：当结构化 观测由图像条件估计并可能缺失或退化时，融合模型怎样保留统一接口和可审计回退。 因此，本文不把软传感器带来的变化解释成独立硬件模态增益。

2.3 低质量与缺失模态学习

缺失模态鲁棒性大致可分为质量感知融合、表示恢复和不确定性建模三类。动态质量 融合根据输入状态改变模态权重[9]；分布一致恢复和概率蒸馏 利用可用模态补全缺失表示[10], [12]；偶然不确定性方法 则尝试从噪声水平调节模态贡献[11]。这些路线为本文提供了 方法依据，但没有直接处理图像条件4×4网格的空间质量、视觉–文本预测 网格与观测网格的一致性，以及同一垃圾分

类检查点上的可靠性路径干预。本文的 差异不在于单独使用注意力、FiLM 或异方差，而在于围绕该软传感器来源组织回退、 质量证据和评价闭环。

3 数据与方法

3.1 任务定义与数据治理

给定 RGB 目标裁剪x、19 个类别文本描述构成的原型集合E、可选软传感器网格 $g \in \mathbb{R}^{4\times4}$及其可用性$a \in \{0,1\}$，模型输出类别 $y \in \{1,\dots,19\}$。对象级主模型不预测边界框或掩码。类别名称沿用原始标注 本体，包含厨余、容器、电池、建材、陶瓷和药品包装等对象，但并非法律或行业标准意义上的垃圾大类，也不等同于医疗废物类别体系。

冻结数据版本包含 8654 条对象记录和 5990 张源图。划分以哈希化 source_image_id 为分组单位，同一源图中的对象只进入训练、验证或测试 之一。表 1 给出数据组成。测试集 826 条对象来自 570 张源图，后续区间 估计据此按源图聚类。

表 1 内部数据划分与软传感器来源。

集合	对象数	源图数	Qwen 辅助	rule-v1 回退
训练集	7002	4823	6989	13
验证集	826	597	826	0
测试集	826	570	824	2
合计	8654	5990	8639	15

数据审计发现 8 组完全相同的对象裁剪身份，冻结测试协议中对应 1 条额外记录；剔除后 测试对象为 825 条，主模型结论未改变。跨集合没有字节级重复，但保守的感知哈希、 灰度误差和相关性联合筛查得到 24 对高置信近重复候选，涉及 40 张源图；其中测试集 8 张源图包含 9 个对象。预定义剔除敏感性同样未改变主要点估计。上述检查证明了源图 文件隔离，却不能证明缺失元数据下的拍摄批次或物体实例完全独立。数据还具有明显 长尾，训练集最大类与最小类相差 29.75 倍，测试最小类别仅 5 条，因此本文同时报告 Macro F1、逐类结果和源图簇区间。

3.2 图像条件软传感器

每条 sidecar 保存重量、温度、湿度、电导率、气味指数和一张 normalized_grid。当前网络只读取4×4网格，五个标量仅用于来源 审计和未来硬件 schema 对接。Qwen3-VL-Flash 接收目标裁剪和不含类别字段的固定 提示词，输出结构化属性；Qwen3-VL 模型族的视觉语言能力由技术报告说明 [14]。8639 条记录通过结构和数值校验，另有 15 条在六次重试后 仍不满足网格或数值约束，因而采用确定性 rule-v1 完整记录回退。最终记录有效率为 100%，Qwen 辅助覆盖率为 99.83%。

这些网格与 RGB 裁剪共享图像来源，本文将其定义为**图像条件软传感器观测**。 该定义允许研究统一接口、软件退化和缺失回退，却不赋予网格真实重量、温湿度、 电导率或气味的物理量含义。托管服务的精确修订版未冻结，复现实验直接使用校验后 的本地 sidecar，而不是重新调用接口以期待逐字节一致。

3.3 视觉与文本表示

RGB 裁剪经过双边滤波、低亮度条件 CLAHE、Laplacian 锐化、单位仿射变换和 480×480缩放。YOLO11s-seg[15]的三个尺度特征 $F_k(x)$经全局平均池化和独立线性投影得到 512 维 token，随后由可学习尺度先验 聚合：

$$z_k = P_k(\mathrm{GAP}(F_k(x))), \qquad v = \sum_{k=1}^{3} \mathrm{softmax}\,(p)_k z_k.$$

正式配置的尺度先验初始化为$0.3/0.5/0.2$，YOLO 前 5 层冻结。

CLIP ViT-B/16 文本塔[16]一次编码 19 条类别描述，得到归一化 原型矩阵E。模型不向文本分支输入真实标签，而以视觉 token 查询全部原型：

$$t_v = \mathrm{softmax}\left(\frac{\cos(v, E)}{\tau}\right) E, \qquad \tau = 0.07.$$

该早期文本上下文既提供类别语义，也作为预测传感器潜表示的条件。

3.4 潜表示预测与缺失回退

4×4网格逐样本标准化后上采样到16×16，经1×1卷积和全局 池化得到 512 维观测表示s。视觉与文本上下文共同预测潜表示均值μ_s和有界 对数方差：

$$\mu_s = g_\mu([v, t_v]), \qquad \log\sigma_s^2 = l_{\min} + (l_{\max} - l_{\min})\mathrm{sigmoid}(g_\sigma([v, t_v])),$$

其中$l_{\min} = -3$、$l_{\max} = 2$。异方差形式借鉴视觉任务中对数据噪声的建模 [17]。模型进一步计算归一化重建差异D、平均预测方差 U和余弦一致性C：

$$\begin{aligned} D &= \mathrm{mean}((s - \mu_s)^2 \exp(-\log\sigma_s^2)), \\ U &= \mathrm{mean}(\exp(\log\sigma_s^2)), \\ C &= \frac{\cos(s, \mu_s) + 1}{2}. \end{aligned}$$

实现先截断D和U，再把$\log(1 + D)$与$\log(1 + U)$送入可靠性头，以避免极端 方差导致数值不稳定。

3.5 跨模态质量与可靠性门控

模型从观测网格提取均值、标准差、动态范围、水平梯度、垂直梯度、饱和率和 flatness 七项统计。另由$[v, t_v, \mu_s]$解码预测 clean 网格$\hat{g}$，将观测网格与 stopgrad$(\hat{g})$组合为 22 维跨模态质量特征，包括两组网格统计、 MAE、RMSE、最大误差、均值偏差、余弦相似度、梯度差和 availability。停止梯度 避免质量头通过改变预测网格投机降低校准目标。

最终可靠性由潜表示证据、原始网格质量和跨模态网格差异三个 logit 残差共同决定：

$$r = a \cdot \mathrm{sigmoid}\big(h_{\mathrm{lat}}([\log(1 + D), C, \log(1 + U), a]) + h_{\mathrm{grid}}(q_g) + h_{\mathrm{cross}}(q_{g,\hat{g}})\big).$$

$$s_{\mathrm{eff}} = \mu_s + r(s - \mu_s).$$

上述门控关系是本文方法的核心：当$a = 0$时，$r = 0$且 $s_{\mathrm{eff}} = \mu_s$，模型完全回退；当观测可用但质量较低时，r连续缩小 观测残差；只有可靠性较高时，表示才接近s。该设计与低质量模态动态融合和不确定 性调节的研究动机一致[9], [11]，但r只表示 当前软传感器及已定义退化下的相对可用性，不是物理测量置信度。

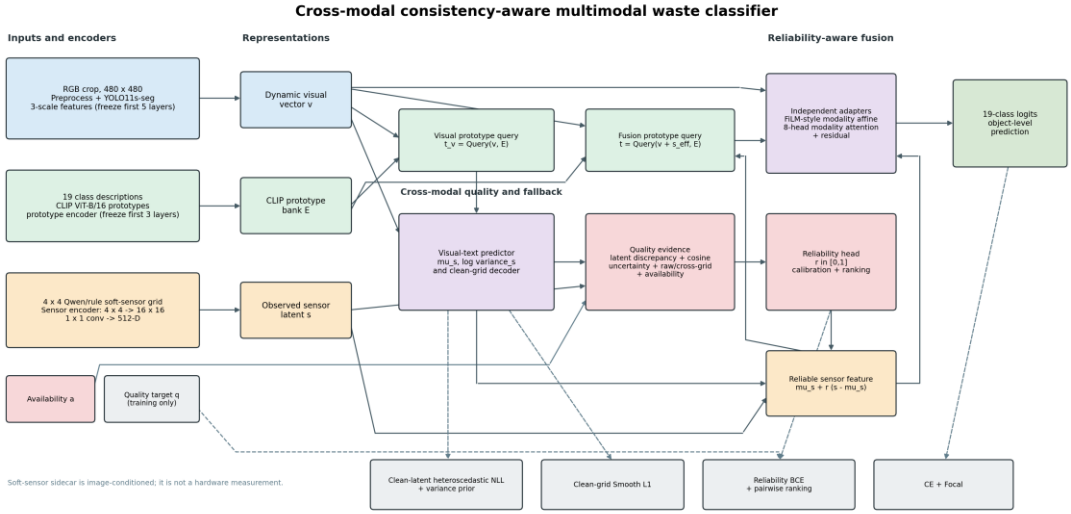


图 1 跨模态一致性感知的可靠多模态垃圾分类框架。RGB 目标裁剪、类别文本原型 和4 × 4图像条件软传感器分别编码；视觉–文本上下文预测传感器潜表示和 clean 网格，多类质量证据估计可靠性，缺失时有效传感器表示回退到预测潜表示。 图中网格来自 Qwen/rule 图像条件 sidecar，不是同步硬件测量。

3.6 融合与训练目标

视觉和有效传感器共同查询类别原型，得到最终文本上下文。三个 512 维模态分别经过 Adapter、LeakyReLU 和 dropout，再由 FiLM-style 逐模态仿射参数调制；FiLM 原始形式 参见[18]，但本文的γ/β是全局参数，不是文本动态生成 网络。模态 token 下投影到 128 维后执行 8 头自注意力，并与动态细化的 YOLO 尺度表示 残差融合。

总目标包含交叉熵、Focal Loss[19]及五项辅助目标：

$$\begin{aligned}\mathcal{L}_{\text{cls}} &= w_{\text{ce}}\mathcal{L}_{\text{CE}} + w_{\text{focal}}\mathcal{L}_{\text{Focal}},\\ \mathcal{L}_{\text{rec}} &= \text{mean}\left[\frac{1}{2}((\mu_s - \text{stopgrad}(s_{\text{clean}}))^2\exp(-\log\sigma_s^2) + \log\sigma_s^2)\right],\\ \mathcal{L} &= \mathcal{L}_{\text{cls}}w_{\text{rec}}\mathcal{L}_{\text{rec}}w_{\text{cal}}\mathcal{L}_{\text{cal}}w_{\text{var}}\mathcal{L}_{\text{var}}w_{\text{grid}}\mathcal{L}_{\text{grid}}w_{\text{rank}}\mathcal{L}_{\text{rank}}.\end{aligned}$$

其中$\mathcal{L}_{\text{cal}}$为可靠性质量目标的加权二元交叉熵， $\mathcal{L}_{\text{var}}$约束对数方差先验， $\mathcal{L}_{\text{grid}}$以 Smooth L1 重建 clean 网格， $\mathcal{L}_{\text{rank}}$约束成对样本的退化质量顺序。正式权重依次为 $w_{\text{rec}} = 0.1$、$w_{\text{cal}} = 0.3$、$w_{\text{var}} = 0.1$、 $w_{\text{grid}} = 0.5$和$w_{\text{rank}} = 0.05$，分类两项权重均为 1。

训练时随机施加 missing、noise、bias/drift 和 stuck。missing、noise、bias 与 stuck 的触发概率分别为 0.10、0.50、0.25 和 0.15；noise 标准差从 [0.02,0.15]采样，bias 最大强度为 0.15。除 missing 外，其余退化允许叠加。 验证与 clean test 关闭随机退化，鲁棒性实验采用固定场景和固定扰动种子。

4 实验设计

4.1 实现设置

正式对象分类实验运行于 Windows 11、Intel Core i9-14900KF、31.8 GB 内存和 NVIDIA RTX 4090 24 GB 环境。软件版本为 Python 3.9.23、PyTorch 2.6.0+cu126、Ultralytics 8.4.70 和 Transformers 4.57.0。训练采用 AdamW， batch size 为 16，初始学习率10^{-4}，weight decay 为10^{-5}，前 5 轮线性 warmup，随后余弦衰减，共 100 个 epoch。最佳检查点只按验证指标保存，测试集不参

与 梯度、学习率或检查点选择。种子 42 为冻结主模型；种子 43 和 44 用于描述训练随机性， 未按测试结果替换主种子。

4.2 比较设计

主要确认性比较为完整 v3 与“无可靠性子系统”变体。后者移除传感器潜表示预测、 可靠性门控、原始和跨模态网格质量及相关辅助损失，但保持软件退化训练、三模态 编码、注意力融合、数据、优化器和 100 轮日程一致；三个变体分别与种子 42、43、 44 匹配。该独立重训比较回答“可靠性子系统在训练适应后是否仍带来收益”。

另进行同检查点干预：固定 seed42 完整模型及所有输入，只关闭可靠性路径，比较同一 批样本的预测变化。该实验回答“已学习的 gate 是否实际改变模型行为”，不能替代 独立重训。历史视觉/文本/传感器结构消融、类别平衡候选和 Qwen/rule-v1 来源重训 均只有单个训练种子，因此归为支持性或负结果，不与主要三种子证据混称。

4.3 指标与统计

分类指标包括 Accuracy、Macro Precision、Macro Recall、Macro F1、Weighted F1、 Top-3 Accuracy、负对数似然、多类 Brier score 和 15 箱 ECE；ECE 的使用背景参见 [20]。单模型区间按 570 个源图簇执行 2000 次百分位 bootstrap。 模型差值按相同源图簇执行 5000 次配对 bootstrap，候选与参考共享每次重采样的簇。 精确 McNemar 检验只作为 826 个对象正确/错误不对称的敏感性统计，不校正同图多对象 相关性。历史多消融比较对 McNemar 的p值采用 Holm 校正，主要解释仍以源图簇区间 和训练种子方向为准。

4.4 软件退化协议

固定 seed42 训练检查点，在五个扰动实现种子上评估 clean、完全缺失 missing_100、标准差 0.15 的 noise_015、强度 0.08 的 bias_008、卡死值 stuck 和混合退化 mixed。这些扰动 种子只表示同一已训练模型上的软件注入重复，不是独立训练种子。评价同时比较 完整模型和匹配训练的无可靠性变体；同检查点 no-gate 曲线只用于机制诊断。

5 结果与讨论

5.1 内部测试表现与训练种子稳定性

表 2 给出完整 v3 三个训练种子的固定内部测试结果。冻结主模型 seed42 取得 88.14% Accuracy、82.44% Macro F1 和 2.46% ECE；按源图聚类的 Accuracy 95%描述性区间为$[85.33\%, 90.79\%]$，Macro F1 区间为 $[76.46\%, 86.22\%]$。三个训练种子的平均 Accuracy 为 $88.26\% \pm 0.21$个百分点，Macro F1 为$82.26\% \pm 0.31$个百分点。seed43 的 Accuracy 略高，但没有据此替换 seed42，因而该汇总不包含事后最佳种子选择。

表 2 完整 v3 在三个训练种子上的内部测试结果。

训练种子	Accuracy	Macro P	Macro R	Macro F1	ECE
42	88.14%	81.60%	84.89%	82.44%	2.46%
43	88.50%	81.38%	85.07%	82.45%	2.87%
44	88.14%	81.14%	84.48%	81.90%	2.96%
均值±样本标准差	88.26 ± 0.21	81.37 ± 0.23	84.81 ± 0.30	82.26 ± 0.31	2.76 ± 0.27

Accuracy 与 Macro F1 之间约 6 个百分点的差距与类别长尾一致。最少类别在测试集中 只有 5 条记录，个别错误即可显著改变该类 F1。因此，表 2 支持的是 内部总体表现和训练种子稳定性，而不是每个少数类都已获得稳定改善。

5.2 可靠性机制的匹配消融

表 3 给出完整 v3 减去匹配无可靠性变体的差值。三个训练种子上的 Accuracy 和 Macro F1 均为正，平均差值分别为+0.81 和+0.51 个百分点。该方向一致性 说明可靠性子系统在允许基线重新训练适应后仍提供温和收益。另一方面，seed42 和 seed43 的 Accuracy 区间以及三个种子的 Macro F1 区间均跨越零；只有 seed44 的 Accuracy 区间下界高于零。因而“方向一致”不能改写为所有单种子效应均显著。

表 3 完整 v3 相对匹配无可靠性重训变体的对象级差值。差值为完整模型减参考； 区间采用 5000 次配对源图簇 bootstrap。

训练种子	Accuracy 差值/百分点（95%区间）	Macro F1 差值/百分点（95%区间）	McNemar p
42	$+0.36\ [-0.94, +1.68]$	$+0.53\ [-1.51, +3.00]$	0.7201
43	$+0.73\ [-0.58, +2.13]$	$+0.27\ [-2.49, +3.32]$	0.3616
44	$+1.33\ [+0.12, +2.62]$	$+0.73\ [-1.01, +2.61]$	0.0614
均值±样本标准差	$+0.81 \pm 0.49$	$+0.51 \pm 0.23$	–

同检查点干预提供了另一层证据。固定 seed42 完整检查点，开启 gate 相对关闭 gate 的 Accuracy 提高 2.78 个百分点，95%区间为[1.23,4.33]；Macro F1 提高 3.50 个 百分点，区间为[1.46,5.89]，精确 McNemar $p = 0.0001911$。这一效应大于独立 重训均值，原因可能是重训后的无可靠性模型能够通过其余路径部分适应，而在完整 检查点中强制关闭 gate 会直接破坏已学习的表示使用方式。这是受结果约束的解释， 并非新的因果证明；同检查点干预只能说明 gate 在该模型中确实改变了预测行为。

5.3 软件退化下的抑制与回退

表 4 和图 2 比较固定 seed42 模型在六个场景下 的效应。完整 v3 在 missing、noise、bias、stuck 和 mixed 中的 Accuracy 与 Macro F1 差值均为正，其中完全缺失和强噪声的 Macro F1 差值分别为 +2.04 和+2.12 个百分点。 这与上述门控关系的预期一致：缺失时模型完全使用预测潜表示，网格偏移或 卡死时则由质量证据缩小观测残差。

表 4 固定 seed42 检查点在注册软件退化下，完整 v3 相对匹配无可靠性变体的 支持性效应。ECE 改善为正表示完整 v3 的 ECE 更低。

场景	Accuracy 效应/百分点	Macro F1 效应/百分点	ECE 改善/百分点
clean	+0.36	+0.53	+0.08
missing_100	+0.97	+2.04	+0.74
noise_015	+1.38	+2.12	-0.06
bias_008	+0.80	+1.35	-0.03
stuck	+0.85	+0.91	+0.47
mixed	+0.73	+0.93	+0.42

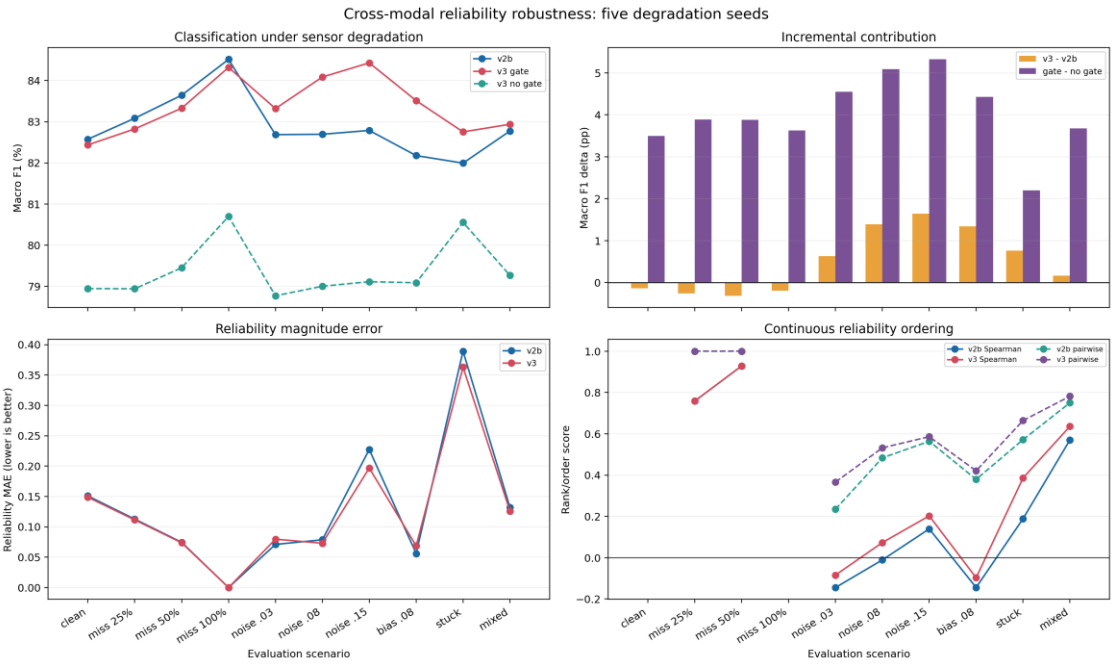


图 2 v2b、v3 及 v3 同检查点关闭可靠性门控在 clean、missing、noise、bias、 stuck 和 mixed 软件退化下的分类与可靠性表现。每个随机退化场景由五个固定扰动 种子汇总；这些种子不是独立训练种子。软件退化也不等同于真实硬件故障。

校准结果并非在所有场景同步改善。noise 和 bias 下的 ECE 改善为-0.06 和-0.03 个 百分点，幅度虽小，却说明分类收益不能被概括为全面校准成功。表 4 又只固定一个训练检查点，因而属于支持性退化证据；主要 确认性结论仍来自表 3 的三个匹配训练种子。

5.4 潜表示不确定性诊断

图 3 在 826 条测试样本、512 维传感器潜空间中比较预测方差和 实际潜表示误差。v3 的样本均值 Spearman 相关系数为 0.892，说明较高预测方差通常 对应较大潜表示误差；相对 v2b，该相关性增加 0.070，事后源图簇 bootstrap 区间为 [0.0477,0.0954]。同时，预测方差与实际 MSE 之比仍为 44.3，标准化残差绝对值 小于 1.96 的覆盖率接近 100%。因此，当前异方差具有较好的相对排序，却在绝对尺度 上明显过分散。

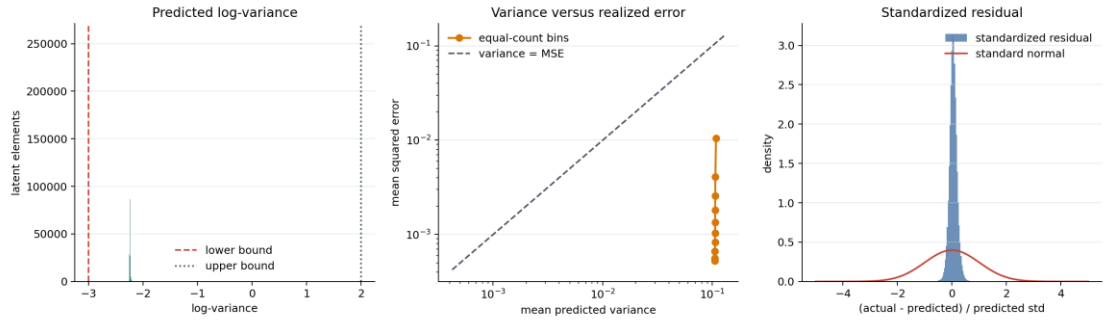


图 3 v3 在固定内部测试样本、512 维传感器编码空间上的异方差诊断。左图为 预测对数方差及配置边界，中图比较等频分箱后的预测方差和潜表示均方误差，右图 比较标准化残差与标准正态密度。该诊断不具有物理传感器单位。

这一结果也解释了为何不应只从异方差重建损失的符号判断训练质量。高斯 NLL 包含 对数方差项，数值可以为负；本文已把下界由早期配置的-6 调到-3 并增加方差先验， 聚合重建项不再贴近理论下限。然而，方差先验和范围约束只缓解数值塌缩，并未完成 量值校准。当前不确定性更适合作为可靠性排序特征，而不是物理测量误差估计。

5.5 负结果、来源敏感性与适用范围

较早谱系的八项结构消融均只有一个训练种子，配对 McNemar 检验经 Holm 校正后的 最小p值为 0.4767，因此不支持“某单一组件已被显著证明必要”的表述。类别平衡 候选提高了部分少数类 Recall，却未提高验证或测试 Macro F1，因而按冻结门槛停止 后续种子。图 4 给出 v2b 与 v3 的逐类 F1 及训练支持量，用于展示长尾差异， 不用于继续按测试类别调参。

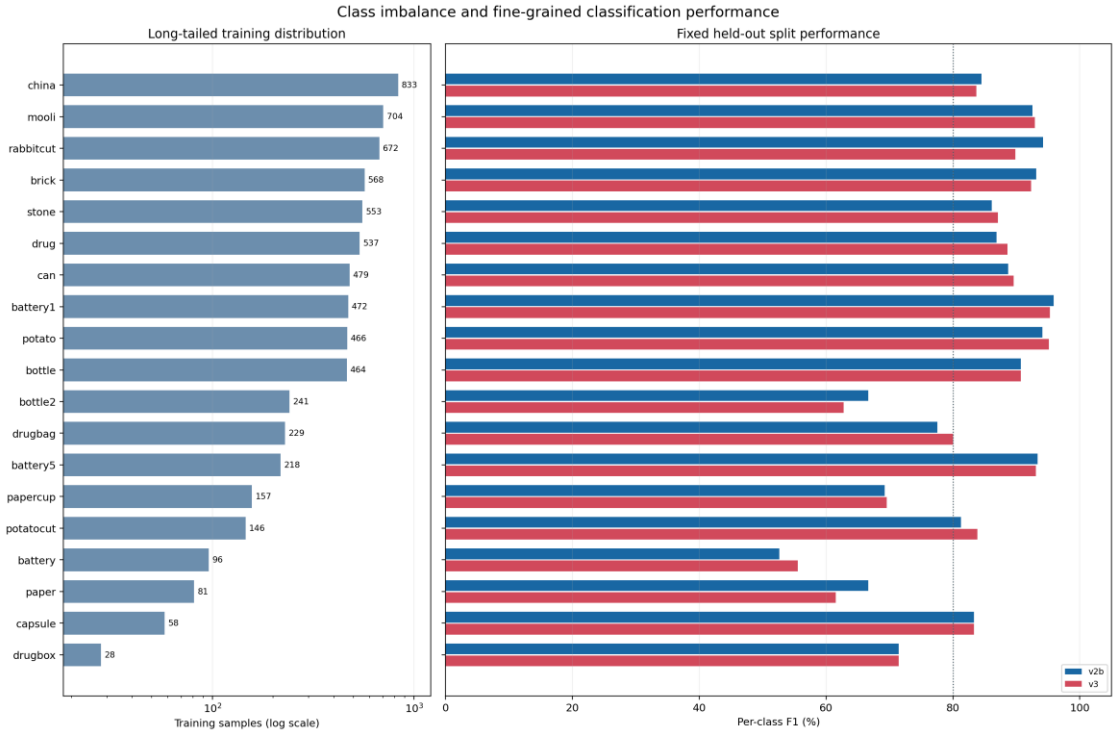


图 4 v2b 方差先验模型与 v3 跨模态质量模型在固定 826 条内部测试记录上的逐类 F1 及训练支持量。逐类差异为单训练种子描述，不包含训练种子方差。

在软传感器来源独立重训中，Qwen sidecar 模型的 Accuracy/Macro F1 为 88.14%/82.44%，rule-v1 模型为 87.29%/81.87%。该比较只有 seed42，配对区间 也跨越零；两种 sidecar 又都由图像条件生成，因此不能据此声称视觉语言模型或真实 传感器带来稳定增益。直接用 RGB 学生蒸馏 Qwen 网格的扩展实验同样没有提高任务 Accuracy，本文保留这一负结果，不把软目标拟合改写成分类收益。

系统扩展方面，独立 RGB YOLO11s-seg 在 570 张测试源图、825 个唯一对象上取得 box mAP50-95 96.55%和 mask mAP50-95 95.13%。把文本与 RGB 预测软传感器 adapter 接入原生 Segment head 后，三个种子的 box/mask mAP50-95 为 97.09% ± 0.02和95.34% ± 0.02个百分点，变化较小；正式前向仍只读取 RGB。该扩展说明接口能够接入目标域分割头，但不属于对象级可靠性收益，也不是 RGB-D 或硬件多模态验证。

当前结论还受到四项外部有效性限制。第一，固定测试集虽然未参与梯度训练，却已用于 多轮研究路线判断，不能称为从未访问的最终盲测。第二，元数据缺少采集批次和物体 实例 ID，源图分组不能完全排除相邻帧或同批次弱相关。第三，最少类别样本很少， Macro F1 和逐类估计存在较宽区间。第四，外部盲测协议与工具链已经冻结，但尚无 独立外部数据；同步物理阵列、时间配准和物理量校准也未完成。原专利方向中的 多尺度视觉、文本语义、4 × 4网格接口和融合调节已有部分结构对齐，但当前 输入是 RGB 而非 RGB-D，网格不是硬件采集，故不能表述为完整专利复现。

6 结论

本文针对图像条件软传感器可能缺失或退化的问题，提出结合视觉–文本条件潜表示 预测、跨模态网格质量和异方差不确定性的可靠多模态垃圾分类方法。有效传感器表示 被写成预测潜表示与观测残差的连续插值，使模型在同一结构中实现正常利用、退化 抑制和完全缺失回退。三个匹配训练种子的内部实验显示，完整方法相对无可靠性变体 获得方向一致但幅度温和的 Accuracy 和 Macro F1 收益；同检查点干预、软件退化和 潜空间诊断进一步支持门控确实改变了证据使用方式。

上述证据限定于 19 类内部固定基准及图像条件 sidecar。潜空间不确定性能够排序误差， 但绝对尺度仍保守；当前结果也不等价于外部泛化、同步硬件测量或真实智能垃圾桶 部署性能。下一步应保持现有 schema 和冻结评价协议，接入与 RGB 同步采集的物理阵列， 按采集批次重新划分数据，并在模型及分析方案冻结后执行一次性外部盲测。

补充说明：复现与完整性事件

正式对象级训练所用配置、环境依赖、检查点 SHA-256、逐样本预测和统计产物均在 本地证据归档中绑定。基础消融期间，一张仅属于训练集的源图发生稳定完整解码错误， 恢复流程没有改写原数据，而是把该路径只读映射到同名、同尺寸、同长度且哈希锁定 的可解码镜像，并从前一完整检查点继续。另一个变体的第 68 轮检查点容器损坏且缺少 完整恢复状态，正式结果由原冻结配置从第 1 轮重新训练 100 轮获得。这些事件未涉及 验证或测试输入，均作为复现偏差披露，也不用于解释模型间性能差异。

参考文献

[1] G. White, C. Cabrera, A. Palade, F. Li, and S. Clarke, “WasteNet: Waste classification at the edge for smart bins,” *arXiv preprint arXiv:2006.05873*, 2020, Available: https://arxiv.org/abs/2006.05873

[2] P. F. Proença and P. Simões, “TACO: Trash annotations in context for litter detection,” *arXiv preprint arXiv:2003.06975*, 2020, Available: https://arxiv.org/abs/2003.06975

[3] D. Bashkirova *et al.*, “ZeroWaste dataset: Towards deformable object segmentation in cluttered scenes,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 21147–21157. Available: https://openaccess.thecvf.com/content/CVPR2022/html/Bashkirova_ZeroWaste_Dataset_Towards_Deformable_Object_Segmentation_in_Cluttered_Scenes_CVPR_2022_paper.html

[4] S. Inácio, H. Proença, and J. C. Neves, “SortWaste: A densely annotated dataset for object detection in industrial waste sorting,” in *Proceedings of the IEEE/CVF winter conference on applications of computer vision workshops*, 2026, pp. 576–584. Available: https://openaccess.thecvf.com/content/WACV2026W/WasteVision/html/Inacio_SortWaste_A_Densely_Annotated_Dataset_for_Object_Detection_in_Industrial_Waste_Sorting_WACVW_2026_paper.html

[5] J. Crall, “ScatSpotter: A dog poop detection dataset,” in *Proceedings of the IEEE/CVF winter conference on applications of computer vision workshops*, 2026, pp. 549–558. Available: https://openaccess.thecvf.com/content/WACV2026W/WasteVision/html/Crall_ScatSpotter_A_Dog_Poop_Detection_Dataset_WACVW_2026_paper.html

[6] M. Bihler *et al.*, “Multi-sensor data fusion using deep learning for bulky waste image classification,” in *Automated visual inspection and machine vision v*, in Proceedings of SPIE, vol. 12623. 2023, p. 126230B. doi: 10.1117/12.2673838.

[7] S. Casao *et al.*, “SpectralWaste dataset: Multimodal data for waste sorting automation,” in *2024 IEEE/RSJ international conference on intelligent robots and systems*, 2024, pp. 5852–5858. doi: 10.1109/IROS58592.2024.10801797.

[8] M. Ma, J. Ren, L. Zhao, D. Testuggine, and X. Peng, “Are multimodal transformers robust to missing modality?” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 18177–18186. Available: https://openaccess.thecvf.com/content/CVPR2022/html/Ma_Are_Multimodal_Transformers_Robust_to_Missing_Modality_CVPR_2022_paper.html

[9] Q. Zhang *et al.*, “Provable dynamic fusion for low-quality multimodal data,” in *Proceedings of the 40th international conference on machine learning*, in Proceedings of machine learning research, vol. 202. 2023, pp. 41753–41769. Available: https://proceedings.mlr.press/v202/zhang23ar.html

[10] Y. Wang, Z. Cui, and Y. Li, “Distribution-consistent modal recovering for incomplete multimodal learning,” in *Proceedings of the IEEE/CVF international conference on computer vision*, 2023, pp. 22025–22034. Available: https://openaccess.thecvf.com/content/ICCV2023/html/Wang_Distribution-Consistent_Modal_Recovering_for_Incomplete_Multimodal_Learning_ICCV_2023_paper.html

[11] Z. Gao, X. Jiang, X. Xu, F. Shen, Y. Li, and H. T. Shen, “Embracing unimodal aleatoric uncertainty for robust multimodal fusion,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2024, pp. 26876–26885. Available: https://openaccess.thecvf.com/content/CVPR2024/html/Gao_Embracing_Unimodal_Aleatoric_Uncertainty_for_Robust_Multimodal_Fusion_CVPR_2024_paper.html

[12] M. Chen, F. Zhang, Z. Zhao, J. Yao, Y. Zhang, and Y. Wang, “Probabilistic conformal distillation for enhancing missing modality robustness,” in *Advances in neural information processing systems*, 2024. Available: https://proceedings.neurips.cc/paper_files/paper/2024/hash/3fb97beb678a1c46bf25f40b3a8c6f98-Abstract-Conference.html

[13] Y. Zhuang *et al.*, “Hyper-modality enhancement for multimodal sentiment analysis with missing modalities,” in *Advances in neural information processing systems*, 2025. Available: https://proceedings.neurips.cc/paper_files/paper/2025/hash/d079de28c5e3f22e3507db24e870126b-Abstract-Conference.html

[14] S. Bai, Y. Cai, R. Chen, K. Chen, and others, “Qwen3-VL technical report,” *arXiv preprint arXiv:2511.21631*, 2025, doi: 10.48550/arXiv.2511.21631.

[15] Ultralytics, “Ultralytics YOLO11.” Official documentation, 2024. Available: https://docs.ultralytics.com/models/yolo11

[16] A. Radford *et al.*, “Learning transferable visual models from natural language supervision,” in *Proceedings of the 38th international conference on machine learning*, in Proceedings of machine learning research, vol. 139. 2021, pp. 8748–8763. Available: https://proceedings.mlr.press/v139/radford21a.html

[17] A. Kendall and Y. Gal, “What uncertainties do we need in bayesian deep learning for computer vision?” in *Advances in neural information processing systems*, 2017. Available: https://papers.neurips.cc/paper/7141-what-uncertainties-do-we-need-in-bayesian-deep-learning-for-computer-vision

[18] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, “FiLM: Visual reasoning with a general conditioning layer,” in *Proceedings of the AAAI conference on artificial intelligence*, 2018. doi: 10.1609/aaai.v32i1.11671.

[19] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proceedings of the IEEE international conference on computer vision*, 2017, pp. 2980–2988. Available: https://openaccess.thecvf.com/content_iccv_2017/html/Lin_Focal_Loss_for_ICCV_2017_paper.html

[20] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, “On calibration of modern neural networks,” in *Proceedings of the 34th international conference on machine learning*, in Proceedings of machine learning research, vol. 70. 2017, pp. 1321–1330. Available: https://proceedings.mlr.press/v70/guo17a.html